



Machine Learning for Petroleum Engineers Using Python

Módulo 5 · Clase 2

El Pozo Avisa Antes de Romperse — Detectar en Señales de Sensores



Carlos Enrique Mosquera Trujillo



SLB Ecuador

Dónde Estamos: la Segunda Clase del Módulo 5

✓ Ya saben:

- ✓ Que un dato con **orden en el tiempo** no se puede barajar (M5-C1)
- ✓ Predecir una **etiqueta** con **Random Forest** (M3-C3)
- ✓ Que hay que **validar dejando pozos completos por fuera** (M3-C5)
- ✓ Que el error se mide en **dólares**, no en puntos

Nada de esto se da por sabido: cada pieza que usemos hoy se vuelve a explicar desde cero cuando aparece.

▶▶ Hoy:

- Una pregunta nueva: ya no *cuánto*, sino **cuándo y qué hago**
- Sensores reales de **pozos submarinos**, a una medición por segundo
- **Descomponer** una señal para convertirla en una tabla
- ★ Y una sorpresa: el salto grande **no lo da el modelo**

Cerramos con el marcador contra la alarma que hoy está instalada en la sala de control.

Ustedes Ya Hacen Esto

Antes de que aparezca una sola fórmula: el trabajo de hoy ya lo saben hacer.

SU PROBLEMA DIARIO

Un operador mira la pantalla del pozo y dice: «*este pozo hoy está raro*».

No calculó nada. Comparó lo que ve contra lo que ese pozo **suele** hacer, miró **varias** pantallas a la vez, y notó que la cosa **venía cambiando** hace rato.

Eso que hizo el operador tiene tres partes, y son exactamente las tres que vamos a programar hoy:

- contra **lo que ese pozo suele hacer**
- mirando **varias señales juntas**
- atento a que **venía cambiando**

El modelo no va a ser más listo que el operador. Va a hacer lo mismo, en los 40 pozos, las 24 horas.

El Encargo

Un pozo submarino a 1200 metros de profundidad. El choke de producción — la válvula que regula cuánto sale — se está **incrustando**: se le pegan sales por dentro y se va cerrando solo.

La sala de control tiene una alarma. Cuando suena, el pozo ya está en falla.

La pregunta de hoy: ¿cuánto antes se puede saber?

\$ Por qué importa la anticipación:

- ⚠ Si me entero **cuando ya falló**: el pozo se cierra sin avisar, y una intervención submarina necesita **barco**
- ✓ Si me entero **horas antes**: se abre el choke, se inyecta inhibidor, se programa la parada con el resto del campo

🕒 **La unidad de la respuesta:** La respuesta de hoy **no es un porcentaje**. Son **minutos**.

Cada minuto que ganamos es un minuto en que alguien todavía puede hacer algo. Cuando el pozo ya falló, no hay nada que decidir: solo hay que pagar. **Por eso, toda la clase, la métrica va a ser la**

Acotar el Problema (Regla de la Casa)

Ninguna línea de código antes de llenar esta tabla. Ninguna. Nunca.

Pregunta de negocio	¿Cuántos minutos antes de la falla puedo avisarle al operador?
Lo que predigo	Una etiqueta, en cada instante: ¿este pozo está entrando en falla, sí o no?
Con qué	Cinco sensores de fondo y de árbol submarino, una medición cada 30 segundos
Métrica de éxito	Dos, juntas: cuántos casos detecta (de 10) y a los cuántos minutos
Récord a batir	La alarma que hoy está instalada. La medimos en un rato: hasta entonces, nadie sabe si es buena o mala

*Fíjense en la última fila. No arrancamos comparando contra cero: arrancamos comparando contra **lo que ya existe y ya funciona**. Un modelo que no le gana a lo instalado no se instala.*


El Pozo y lo que Mide

Qué es un choke, por qué se tapa, y qué es exactamente un archivo de sensores

12 – 42 min

Un Pozo que Nadie Puede Ir a Mirar

Un pozo submarino: cinco sensores, una medición por segundo



- El equipo está en el **lecho marino**. Nadie baja a mirarlo: para tocarlo hace falta un barco y una ventana de buen tiempo.
- Lo único que llega a superficie son **números**. Esos cinco.

¿Qué es un Choke? La Pieza de Toda la Clase

Empecemos por acá, porque si esta pieza no queda clara, nada de lo que sigue tiene sentido.

El **choke** (o estrangulador) es una válvula con un agujero calibrado, puesta a la salida del pozo. Todo lo que el pozo produce pasa obligatoriamente por ese agujero.

Es, literalmente, **la boquilla de la manguera**: si la aprietan, sale menos agua y sale con más fuerza; si la abren, sale más y más floja.

Es la **única perilla** que el operador tiene para controlar cuánto produce un pozo submarino. Nada más se puede tocar desde arriba.


? ¿Y por qué no se deja abierto? Porque producir al máximo rompe cosas:

- Si el pozo va muy rápido, **arrastra arena** y erosiona la tubería
- **Chupa agua** del acuífero antes de tiempo
- La planta de arriba tiene una **capacidad**, y no la puede pasar

Por eso el choke está siempre a medio abrir, en una posición que alguien eligió y anotó.

Lo que le Hace el Choke al Fluido

Lo que le hace el choke al fluido — y qué cambia cuando se tapa



Dos cosas pasan siempre que un fluido cruza un estrangulamiento: la presión **cae** de un lado al otro, y la temperatura **también**.

Por Qué se Enfría: el Efecto Joule–Thomson

Este es el fenómeno físico que hace posible toda la clase de hoy. No se puede dar por sabido.

Cuando un gas pasa de una zona de alta presión a una de baja presión **sin recibir calor de afuera**, se **expande**. Para expandirse tiene que empujar, y esa energía la saca de sí mismo.

Resultado: **se enfría**. Y cuanto mayor es la caída de presión, más se enfría.

❄ LO VIERON MIL VECES

Una garrafa de gas que se está descargando se **escarcha** por fuera. Un aerosol se enfría en la mano. Es lo mismo: gas que se expande, gas que se enfría.

🔗 La cadena completa

1. El agujero del choke se achica
2. Para pasar el mismo fluido por un agujero menor, hay que **empujar más** → la presión de antes **sube**
3. La caída a través del choke es **mayor**
4. Mayor caída → mayor expansión → **más frío del otro lado**

🔑 LA FIRMA A BUSCAR

Presión **arriba** subiendo y temperatura **abajo** bajando, **al mismo tiempo**.

Qué es la Incrustación, y Por Qué se Ve en la Presión

? Qué pasa físicamente El agua de formación trae sales disueltas (carbonatos, sulfatos). Al pasar por el choke la presión cae de golpe, la sal precipita y se **pega a las paredes**.

El agujero por donde pasa el fluido se va **achicando**. Nadie lo abrió ni lo cerró: se cerró solo.

💡 LA CLAVE DE HOY

La incrustación **no es un evento**: es un proceso que tarda horas. Por eso se puede ver venir — si uno sabe dónde mirar.

👁 Qué deja como huella

↑ **Aguas arriba** del choke la presión **sube**: el fluido empuja contra una salida más chica.


↓ **Aguas abajo** la temperatura **baja**: al estrangular más, el gas se expande más y se enfría más (el mismo efecto que enfría una garrafa cuando se descarga).

Guarden estas dos flechas. Dentro de tres láminas las vamos a ver pasar, en un pozo de verdad.

Qué es, Exactamente, una Serie de Tiempo

Una tabla donde cada fila es un instante, y las filas están en orden. Eso es todo. Lo difícil es lo que implica.

La misma medición, acercándose: una serie de tiempo es una fila por instante



→ El sensor mide **una vez por segundo**: 86 400 filas por día, por sensor, por pozo.

→ Nosotros nos quedamos con **una cada 30**

El Archivo: Qué Hay Adentro

Python

```
import pandas as pd

URL =
    ↪ ("https://raw.githubusercontent.com/"
        "cmosquerat/slb-diplomado/main/"
        "datos/pozos_3w_incrustacion.csv")

# leemos el archivo (se baja solo)
d = pd.read_csv(URL)

# ¿cuántas filas y cuántas columnas?
print(d.shape)

# ¿cuántas grabaciones hay, y de que
    ↪ pozos?
print(d.pozo.value_counts())
```

>_ Output

(37822, 9)

WELL-00023	16901
WELL-00024	11772
WELL-00022	3780
WELL-00021	2926
WELL-00001	2443

 **315 horas** de pozo grabadas

 **5 pozos, 12 grabaciones**

✓ Datos **reales**: ni simulados ni dibujados

Las Variables, Una a Una

columna	tag de campo	qué es
p_antes_choke	P-MON-CKP	Presión justo <i>antes</i> de la válvula. Sube si la válvula se tapa
t_despues_choke	T-JUS-CKP	Temperatura justo <i>después</i> . Baja si la válvula se tapa
p_arbol	P-TPT	Presión en el árbol submarino, en la boca del pozo
p_anular	P-ANULAR	Presión en el espacio entre tuberías. Vigila la integridad
p_gaslift	P-JUS-CKGL	Presión del gas que se inyecta para aligerar la columna
etiqueta	class	Lo que hay que predecir. La puso una persona, no un sensor

Cinco columnas, y las cinco se explican en una línea. Ese fue un criterio para elegir este dataset: si una variable necesita un párrafo, la clase se va a hablar de la variable y no del problema.

Qué es una Etiqueta, y Quién la Puso

Esta es la lámina más importante del día, y no tiene ni una fórmula.

La columna etiqueta toma tres valores:

- ✓ **normal** — el pozo trabajando bien
- ⚠ **transitorio** — la incrustación *avanzando*.
Todavía se puede hacer algo
- ✗ **falla** — ya está. Se acabó la ventana

Nuestro objetivo es **cazar el naranja**: avisar durante el transitorio, que es cuando el aviso todavía sirve.



LA ETIQUETA ES UN JUICIO


Estas etiquetas las escribieron **especialistas de Petrobras** mirando las grabaciones, segundo a segundo.

No son la verdad: son **la opinión de una persona experta**. Alguien decidió en qué segundo exacto «empieza» algo que en realidad empezó de a poco.

Anótenlo. Al final de la clase esto nos va a pasar

factura — y va a ser la mejor noticia del día.

La Señal, de Verdad



Ahí están las dos flechas que anotamos: la presión de arriba **sube**, la temperatura de abajo **baja**. La física se ve a simple vista.

Lo Primero que Hace un Ingeniero: Mirar Qué Hay

Lo primero que hay que mirar: ¿qué sensores existen de verdad?

Pozo 01 · 20170226130146	sí	sí	sí	sí	sí
Pozo 21 · 20180611011218	sí	sí	sí	sí	sí
Pozo 21 · 20190403013307	sí	sí	sí	sí	sí
Pozo 22 · 20181101193049	sí	sí	sí	sí	sí
Pozo 23 · 20181014121654	sí	no	no	no	sí
Pozo 23 · 20181030045054	sí	no	no	no	sí
Pozo 24 · 20160825100303	sí	sí	sí	sí	sí
Pozo 24 · 20160828150330	sí	sí	sí	sí	sí
Pozo 24 · 20160830190958	sí	sí	sí	sí	sí
Pozo 24 · 20160911063934	sí	sí	sí	sí	sí
Pozo 24 · 20160920153331	sí	sí	sí	sí	sí
Pozo 24 · 20160923141645	sí	sí	sí	sí	sí
	Presión antes del choke	Temperatura tras el choke	Presión en el árbol	Presión en el anular	Presión del gas lift

solo
2 sensores

Antes de modelar nada: ¿qué sensores existen realmente?

- ⚠ El **pozo 23** tiene solo **dos** sensores vivos. Los otros tres están en el archivo, pero vacíos.
- ➔ Esto no es un defecto del dataset. Es **cómo son los datos de campo**: sensores rotos, no instalados, o que dejaron de reportar.

*Decisión que tomamos acá, en voz alta: el pozo 23 queda **fuera** de la clase, y va a ser el reto de la práctica.*

La Alarma que Ya Existe

Antes de proponer nada nuevo, hay
que medir lo que ya está instalado

42 – 55 min

Cómo Funciona una Alarma de Umbral

Es la lógica más vieja de una sala de control, y funciona así:

1. Se mira una hora de operación normal del pozo y se anota cuánto vale la presión **en promedio**.
2. Se anota también **cuánto se mueve** alrededor de ese promedio: eso es la **desviación estándar**.
3. Se dibuja una banda: promedio $\pm$ tres desviaciones.
4. Si la señal se sale de la banda, **suen**a.

QUÉ ES LA DESVIACIÓN ESTÁNDAR

Es una regla para medir «qué tan raro es un número» **en las unidades de ese pozo**.

Si la presión de un pozo normalmente se mueve $\pm 0,3$ bar, entonces subir 1 bar es **muchísimo**. Si otro pozo se mueve ± 5 bar, subir 1 bar no es nada.

Contar «cuántas desviaciones» es preguntar **cuán raro es esto para este pozo**, no cuántos bar son.

Tres desviaciones es la costumbre de la industria. Ni

La Alarma, en Código

Python

```
pozo = "WELL-00001_20170226130146"
g = d[d.instancia == pozo]      # tomamos UN pozo

# la primera hora es su "normal"
# (120 filas = 120 x 30 s = 1 hora)
primera_hora = g.p_antes_choke.iloc[:120]

centro = primera_hora.median()   # valor tipico
ancho  = primera_hora.std()      # cuanto se
    ↪ mueve

# cuantas desviaciones de distancia hay
# en cada instante
z = (g.p_antes_choke - centro) / ancho


# la alarma suena si se pasa de 3
suena = z.abs() > 3
```

Fíjense en lo que hicimos con z:

- restamos el centro → ahora 0 significa «normal para este pozo»
- dividimos por el ancho → ahora 1 significa «un temblor típico de este pozo»

Esas dos líneas van a ser, dentro de media hora, el hallazgo de toda la clase. Todavía no lo saben.

La Alarma, Puesta a Prueba en un Pozo



La alarma **no se equivocó**: la presión efectivamente se salió de la banda. El problema es *cuándo*. Y en este pozo, dicho sea de paso, no lo hace mal.

Cómo se Mide «Bien» o «Mal»: Tres Números

Si no definimos esto ahora, después cada uno defiende el número que le conviene.

Casos detectados

De los 10 eventos grabados, **¿en cuántos avisó alguna vez?** Si no avisa nunca, el resto no importa

Retraso

¿Cuántos minutos pasaron desde que el evento empezó hasta el primer aviso? Menos es mejor

Falsas alarmas

¿Qué porcentaje del tiempo normal estuvo gritando sin motivo? Una alarma que grita siempre se apaga, y entonces no sirve para nada

⚖️ LA REGLA DE COMPARACIÓN JUSTA

Los tres números se mueven juntos: cualquiera detecta más si acepta gritar más. Por eso, **todo lo que comparemos hoy va a estar obligado a la misma tasa de falsas alarmas que la alarma actual.** Comparar a distinta tasa de falsas alarmas es hacer trampa.

El Récord a Batir

Corrimos la alarma sobre las 10 grabaciones. Este es el número que hay que superar:

CASOS DETECTADOS

8 de 10

dos eventos completos
se le pasaron enteros

RETRASO (MEDIANA)

101 min

casi dos horas
después de empezar

FALSAS ALARMAS

13,5 %

este es el presupuesto
que nadie puede pasar

*Ahora sí sabemos contra qué jugamos. Y noten que la alarma **no es mala**: detecta 8 de 10. El problema es que avisa cuando ya casi no queda nada por hacer.*

De la Señal a una Tabla

Los modelos no comen señales:
comen tablas. Hay que traducir.

55 – 82 min

El Problema de Traducción

✗ **Lo que tenemos** Una **señal**: 37 822 mediciones en fila india, donde el significado de cada número depende de los que vinieron antes.

Un valor de 54 bar no dice nada. **54 bar después de venir de 53 durante ocho horas** lo dice todo.


✓ **Lo que come el modelo** Una **tabla**: filas independientes, donde cada fila se explica sola y el orden no importa.

Es la misma tabla del Módulo 3: una fila por caso, una columna por característica, una etiqueta al final.

✗ EL TRABAJO DE ESTE BLOQUE

Meterle a cada fila, en sus columnas, **el contexto que la señal tenía en el tiempo**. Si lo hacemos bien, el modelo no necesita saber que esto era una serie de tiempo.

Descomponer: Toda Señal es una Suma de Tres Cosas



$$\text{señal} = \text{nivel} + \text{lo que se repite} + \text{ruido}$$

Las Tres Componentes, Una a Una

Ninguna es «la buena»: son tres preguntas distintas sobre el pozo.

componente	cómo se calcula	qué pregunta contesta
El nivel	El promedio de la última media hora	¿Dónde está parada la señal? Acá vive la incrustación
El ruido	La desviación estándar de esa misma media hora	¿Cuánto tiembla? Un pozo tapándose se vuelve más inestable
La pendiente	El valor de ahora menos el de media hora atrás	¿Hacia dónde va, y qué tan rápido?

? QUÉ ES UN PROMEDIO MÓVIL

El promedio de siempre, pero sobre una ventana que **se va corriendo**: para cada instante se miran los últimos 30 minutos y se promedia. Sirve para **sacarle el temblor a la señal**.



La Ventana Deslizante: el Truco Completo



ventana 1	-9.2	8.9	-1.1	uno (los de la tabla por cada ventana)
ventana 2	-1.4	1.1	-1.6	
ventana 3	-1.8	2.3	-1.6	

y así el promedio bajo de ser una serie de tiempos para a ser la tabla de tiempo.

Pero Hay un Problema: Cada Pozo Vive en Otro Mundo



- ⚠ **Izquierda:** un pozo trabaja a 54 bar y otro a 130. Si le damos esto al modelo, aprende a reconocer pozos, no fallas.
- ✓ **Derecha:** las mismas señales, cada una comparada con su propia primera hora. Ahora sí hablan el mismo idioma.

La Línea Base: Comparar Cada Pozo Consigo Mismo

Python

```
def preparar(g):  
    """Traduce una grabacion a filas de  
    ↪ tabla."""  
    X = pd.DataFrame(index=g.index)  
    for s in SENSORES:  
        v = g[s]  
  
        # 1) su propia normal: la primera  
        ↪ hora  
        centro = v.iloc[:120].median()  
        ancho = v.iloc[:120].std()  
  
        # 2) la señal en "desviaciones  
        ↪ propias"  
        z = (v - centro) / ancho  
        X[s + "__base"] = z
```

Línea por línea:

- `iloc[:120]` → las primeras 120 filas, o sea la primera hora
- `median()` → el valor típico. Usamos mediana y no promedio porque un solo pico no la mueve
- `rolling(60)` → la ventana de 60 filas = 30 minutos
- `diff(60)` → cuánto cambió respecto de media hora atrás

20 columnas: 4 por cada uno de los 5 sensores.

El Modelo

Y la sorpresa: el escalón que
más vale no es el algoritmo

82 – 102 min

Random Forest, Otra Vez y Desde Cero

🌲 **Un árbol de decisión** Es una cadena de preguntas de sí o no, aprendidas del dato:

¿el nivel de temperatura bajó más de 1,2?

→ *sí: ¿y el de presión subió más de 0,8?*

→ *sí: esto es una falla.*

Un solo árbol es frágil: cambia un dato y cambia todo.

👥 **Un bosque** Se entrenan **300 árboles**, cada uno viendo una porción distinta de los datos y de las columnas. Después **votan**.

Cada árbol se equivoca por su lado; el promedio de los 300 se equivoca mucho menos. Es la sabiduría de la multitud, con árboles.

✓ POR QUÉ ESTE Y NO OTRO

Porque no le importan las escalas, aguanta columnas inútiles sin despeinarse, y — lo que más nos sirve hoy — **nos puede decir en qué columnas se apoyó**. Vamos a usar eso para hacerle una pregunta de física.

Validar con un Pozo que el Modelo Nunca Vio

⊘ ASÍ NO

Mezclar todas las filas y apartar el 20 % al azar.

Cada pozo quedaría a los dos lados: el modelo ya vio ese pozo, ya sabe cómo respira, y en el examen lo reconoce. El número sale hermoso y **es mentira**.

✓ ASÍ SÍ


Sacar **un pozo entero** y entrenar con los otros tres. Después preguntarle por el pozo que nunca vio. Y repetir, dejando afuera cada pozo por turno.

Eso es GroupKFold, agrupando **por pozo**.

La pregunta que responde la forma honesta es la del negocio: **«mañana instalamos esto en un pozo nuevo. ¿Va a funcionar?»**

Todos los números que siguen salen de esta validación. Ninguno se midió sobre datos que el modelo hubiera visto antes.

Cada Escalón Hay que Ganárselo



los cinco medidos con el MISMO presupuesto de falsas alarmas (13 %), el de la alarma actual — comparar a distinta tasa de falsas alarmas es trampa


Lo que Dice la Escalera, Leído Despacio

qué se le dio al modelo	detecta	avisa a los	qué aprendimos
La alarma que ya existe	8 de 10	101 min	el récord
Los números crudos	2 de 10	253 min	peor que la alarma: aprende pozos, no fallas
Comparados con su propia normal	10 de 10	27 min	el salto. Y no lo dio el algoritmo
Además, promediados	9 de 10	34 min	más estable, pero más tarde
Además, ruido y pendiente	8 de 10	59 min	no aportó

★ EL NÚMERO DEL DÍA


Entre la fila 2 y la fila 3 hay **dos líneas de código**: restar la mediana y dividir por la desviación. Pasó de **2 de 10** a **10 de 10**, con el mismo modelo y los mismos datos.

Cuánto Tarda Cada Uno en Darse Cuenta



Diez grabaciones, una por línea. La alarma deja **dos pozos sin detectar**; el modelo no deja ninguno.

Quién Delata la Incrustación




Le preguntamos al bosque en qué se apoyó. La respuesta **no es la presión:** es la **temperatura**.

- La presión sube, sí — pero también sube cuando alguien cierra un poco el choke a propósito.
- ✓ La temperatura aguas abajo **cayendo mientras la presión sube** es la firma de una restricción que *nadie ordenó*.

El modelo redescubrió solo el efecto Joule-Thomson. Y de paso nos dice qué sensor no hay que dejar sin mantenimiento.

No Hay «Un Modelo»: Hay una Perilla



El modelo no dice «sí» o «no»: dice **qué tan seguro está**, de 0 a 1. Nosotros elegimos a partir de qué número suena.

- 🔊 Girar hacia **avisar de más**: no se escapa nada, pero la sala de control termina ignorando la pantalla.
- 🔊 Girar hacia **avisar poco**: cada alerta se toma en serio, pero algunas fallas pasan.

Esa perilla **no la gira el modelo ni el que programa**. La gira quien va a atender la alerta a las tres de la mañana.

Cómo Reportarlo al que Decide

❌ ASÍ NO

«Entrenamos un Random Forest de 300 árboles con validación GroupKFold y obtuvimos un recall de 0,605 con un F1 de 0,71.»

El gerente no sabe si eso es bueno, no sabe qué hacer mañana, y no puede repetirlo en su reunión.



✅ ASÍ SÍ

«Con los mismos sensores y sin gastar un peso en hardware, pasamos de detectar 8 de cada 10 incrustaciones a detectar las 10, y el aviso llega **74 minutos antes**. Sin aumentar las falsas alarmas.

Eso es una hora y cuarto más para abrir el choke antes de que el pozo se cierre solo.»

La diferencia no es de estilo. La versión de la derecha se puede **decidir**: dice qué cambia, cuánto cuesta y qué habilita.

Las Falsas Alarmas que No lo Eran



Si el modelo se equivocara al azar, las alertas del período normal estarían repartidas parejo. **No lo están:** se amontonan al final, justo antes de que el especialista marque el inicio.

La Etiqueta No Era la Verdad

Volvamos a la lámina que les pedí anotar al principio.

- La incrustación **no empieza en un segundo**: empieza de a poco.
- El especialista tuvo que **elegir un segundo** para marcar el comienzo. Eligió el momento en que a él se le hizo evidente.
- ✓ Cuando el modelo avisa antes de esa marca, la métrica lo cuenta como **error**. En un pozo, ese «error» llegó **1 hora y 48 minutos antes**.

💡 LA LECCIÓN INCÓMODA

Una métrica compara al modelo contra la etiqueta, no contra la realidad.

Si la etiqueta es el juicio de una persona, entonces «equivocarse» puede significar acertar antes que ella.

Por eso ningún resultado se cierra sin ir a mirar **dónde** se equivoca.

Su Turno

El pozo que dejamos afuera

102 – 118 min

Su Turno: el Pozo con Dos Sensores

🕒 18 min

*El **pozo 23** tiene 141 horas grabadas y solo **dos** sensores vivos. Es el pozo más real de todos: así llegan los datos cuando nadie los preparó para una clase.*

1. Corran la celda que ya está escrita: arma la tabla del pozo 23 con los dos sensores que sí tiene. **El primer paso ya está resuelto.**
2. Entrenen con los cuatro pozos de la clase y pregúntenle por el 23. ¿Cuántos de sus **dos** eventos detecta? ¿A los cuántos minutos?
3. Giren la perilla. Busquen el umbral que detecta los dos eventos. ¿Cuántas falsas alarmas costó?
4. Comparen contra la alarma de umbral sobre el mismo pozo. ¿Gana el modelo con solo dos sensores?
5. **Pregunta de negocio:** escriban **una frase** para el jefe de operaciones que responda: *¿instalamos esto en el pozo 23, o primero arreglamos los tres sensores muertos?* La frase tiene que decir qué se gana con cada opción.

Cierre

Lo Que Aprendimos Hoy

💡 Conceptos:

- ✓ Toda señal es **nivel + lo que se repite + ruido**
- ✓ Una **ventana deslizante** convierte una señal en una tabla
- ✓ Comparar cada activo **consigo mismo** antes de comparar entre activos
- ✓ Validar dejando **una unidad entera por fuera**
- ✓ Una **etiqueta** es un juicio humano, no la verdad

🔧 Herramientas:

- `.rolling(n).mean().std().diff(n)`
- `RandomForestClassifier`
- `GroupKFold(groups=pozo)`
- `predict_proba` y el **umbral** como decisión

EL NÚMERO DEL DÍA

74 minutos. Lo que se ganó sin comprar un solo sensor nuevo.

Si Se Llevan Una Sola Cosa

El algoritmo no cambió en toda la clase.

El mismo Random Forest pasó de detectar **2 de 10** a detectar **10 de 10** — y lo único que cambió fueron dos líneas que comparan cada pozo con su propia hora normal.

Elegir bien qué se le pregunta al dato valió más que cualquier modelo. Y eso no lo hace la librería: lo hace **alguien que entiende el pozo**.

Por eso este módulo se llama Machine Learning aplicado a ingeniería de yacimientos y producción, y no Machine Learning.

Lo Que Sigue

- ➔ **Clase 3 — Curvas de declinación y cuánto queda.** Arps (1945), la deuda que dejamos anotada en la Clase 1: exponencial, hiperbólica, y el EUR. Ahí vuelve el ciclo estacional que hoy no existía, porque el dato va a ser mensual.
- ➔ **Clase 4 — El agua y el gas como diagnóstico.** WOR, GOR y la llegada del agua: cuándo el yacimiento avisa que está cambiando.
- ➔ **Clase 5 — Bombas ESP y levantamiento artificial.** El mismo método de hoy, sobre el equipo que más se rompe y más caro cuesta reparar.

*Y una promesa que se paga hoy mismo: en la Clase 1 dijimos que íbamos a nombrar la recta sobre el logaritmo. Se llama **declinación exponencial de Arps**, y la completamos en la Clase 3.*

Datos y Referencias

-  **3W Dataset v2.0.0** — Petrobras. github.com/petrobras/3W
Instancias reales de eventos indeseados en pozos costa afuera. Datos bajo licencia **CC BY 4.0**.
-  Vargas, R. E. V. et al. (2019). *A realistic and public dataset with rare undesirable real events in oil wells*. Journal of Petroleum Science and Engineering, 181, 106223.
-  El subconjunto que usamos hoy se arma con `modulo5-clase2/preparar_datos.py`, y todas las figuras y números de estas láminas salen de `figuras.py`. Nada está escrito a mano.

Si quieren repetir cualquier número de hoy: clonan el repositorio, corren los dos scripts, y tiene que dar exactamente lo mismo. Si no da, es un error nuestro y queremos saberlo.

¡Gracias!

Carlos Enrique Mosquera Trujillo

✉ cmosquerat@unal.edu.co

Machine Learning for Petroleum Engineers Using Python

Módulo 5 · Clase 2 · SLB Ecuador · UDLA · 2026